

Universidad Tecnológica de El Salvador



1.PORTADA

FACULTAD DE INFORMATICA Y CIENCIAS APLICADAS

ASIGNATURA:

TÉCNICAS DE PRODUCCIÓN INDUSTRIAL DE SOFTWARE II

DOCENTE:

JORGE MACHADO

SECCION:

01

NOMBRE DEL PROYECTO:

TÉCNICAS DE PRODUCCIÓN INDUSTRIAL DE SOFTWARE

Integrantes.	Carnet.
Jiménez Mendoza Bryan Eduardo	25-2055-2022

INTRODUCCION

En la industria de producción de software, las decisiones sobre la gestión del talento y los perfiles ocupacionales deben respaldarse con datos objetivos. Este informe detalla el análisis técnico realizado para la empresa InnovaSoft Analytics, utilizando el dataset Prestige_modificado.csv procesado en Python. Mediante técnicas análisis de datos, como matrices de correlación y clusterización con K-Means, se examina cómo factores como la educación, los ingresos y la participación femenina impactan el prestigio de diferentes ocupaciones. El objetivo de este análisis es emular una línea de producción analítica para transformar los hallazgos técnicos en recomendaciones gerenciales claras, optimizando la toma de decisiones sobre roles, especialización y mejora de procesos dentro de la compañía.

ACTIVIDAD 1. CARGA DE DATOS

Una vez cargado el dataset, se puede observar a continuación primero el numero de filas (102) y la cantidad de columnas (7). Posteriormente se puede observar las primeras filas de datos del dataset.

```
print(df.shape)
print(df.head())
```

```
*** (102, 7)
```

	occupation	education	income	women	prestige	census	type_num
0	gov.administrators	13.11	12351	11.16	68.8	1113	1
1	general.managers	12.26	25879	4.02	69.1	1130	1
2	accountants	12.77	9271	15.70	63.4	1171	1
3	purchasing.officers	11.42	8865	9.11	56.8	1175	1
4	chemists	14.62	8403	11.68	73.5	2111	1

Después validamos si se hay valores nulos y se hace una suma de ellos, en esta ocasión podemos ver que la sumatoria de números nulos en cada columna es de cero, quiere decir que el dataset está limpio en cuanto a datos faltantes.

```
[21]
✓ 0s print(df.info())
print(df.isnull().sum())
```

```
*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 102 entries, 0 to 101
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   occupation  102 non-null   object
1   education   102 non-null   float64
2   income      102 non-null   int64
3   women       102 non-null   float64
4   prestige    102 non-null   float64
5   census      102 non-null   int64
6   type_num    102 non-null   int64
dtypes: float64(3), int64(3), object(1)
memory usage: 5.7+ KB
None
occupation      0
education        0
income           0
women            0
prestige         0
census           0
type_num         0
dtype: int64
```

La ausencia de registros duplicados garantiza que no hay información redundante que pueda sesgar los resultados, mientras que las métricas descriptivas (como promedios, mínimos y máximos) demuestran que las variables numéricas presentan una distribución lógica y sin valores anómalos o irreales.

```
[22]
✓ 0 s
print(df.duplicated().sum())
print(df.describe())
```

	education	income	women	prestige	census
count	102.000000	102.000000	102.000000	102.000000	102.000000
mean	10.738039	6797.901961	28.979020	46.833333	5401.774510
std	2.728444	4245.922227	31.724931	17.204486	2644.993215
min	6.380000	611.000000	0.000000	14.800000	1113.000000
25%	8.445000	4106.000000	3.592500	35.225000	3120.500000
50%	10.540000	5930.500000	13.600000	43.600000	5135.000000
75%	12.647500	8187.250000	52.202500	59.275000	8312.500000
max	15.970000	25879.000000	97.510000	87.200000	9517.000000

	type_num
count	102.000000
mean	1.843137
std	0.817447
min	0.000000
25%	1.000000
50%	2.000000
75%	2.000000
max	3.000000

ACTIVIDAD 2. ANALISIS DE RELACION ENTRE VARIABLES.

```
[26]
✓ 0 s
variables_numericas = df.select_dtypes(include=['int64', 'float64'])
matriz_correlacion = variables_numericas.corr()

print(matriz_correlacion.round(3))
print(matriz_correlacion['prestige'].sort_values(ascending=False).round(3))
```

	education	income	women	prestige	census	type_num
education	1.000	0.578	0.062	0.850	-0.823	-0.382
income	0.578	1.000	-0.441	0.715	-0.361	-0.368
women	0.062	-0.441	1.000	-0.118	-0.227	0.251
prestige	0.850	0.715	-0.118	1.000	-0.635	-0.465
census	-0.823	-0.361	-0.227	-0.635	1.000	0.288
type_num	-0.382	-0.368	0.251	-0.465	0.288	1.000


```
prestige
education    0.850
income       0.715
women       -0.118
type_num    -0.465
census      -0.635
Name: prestige, dtype: float64
```

Al ejecutar el código para la matriz de correlación, lo primero que debemos de verificar es que si halla correlación y en nuestro caso podemos observar que si existe.


Una vez confirmada la correlación podemos analizar los valores que nos muestra la matriz. Podemos notar que Educación (education = 0.850), es la variable con la correlación positiva más fuerte. Esto indica que, a medida que aumentan los años de educación requeridos para un puesto, su prestigio social sube significativamente.

Por otra parte, Porcentaje de mujeres (women = -0.118) es una relación muy débil y ligeramente negativa. En este conjunto de datos, la participación femenina casi no tiene relación con el prestigio, aunque la leve tendencia negativa podría sugerir una brecha histórica en cómo se valoraban ciertos roles.


Estos resultados son muy coherentes con la realidad laboral. En una empresa productora de software es lógico que los roles que requieren mayor grado de estudios especializados (como arquitectos de software o gerentes) y que perciben salarios más altos, sean los más reconocidos y valorados dentro y fuera de la organización.

Es importante advertir que correlación no implica causalidad. Que el ingreso esté fuertemente correlacionado con el prestigio no significa que, si mañana le triplicamos el sueldo a un rol operativo básico, su percepción de prestigio social aumentará automáticamente en la misma proporción. Hay múltiples factores como la complejidad del trabajo o la preparación que interactúan.

ACTIVIDAD 3. VISUALIZACION DE RESULTADOS



Observamos una clara tendencia ascendente y lineal. Los puntos están agrupados formando una línea diagonal hacia arriba, lo que confirma visualmente nuestra matriz de correlación: a mayor cantidad de años de educación formal, el prestigio de la ocupación aumenta de forma muy consistente.



Aunque la tendencia general es positiva, a más ingresos, más prestigio. Los puntos están mucho más dispersos que en la gráfica de educación. Se observa que algunas ocupaciones con ingresos moderados logran un prestigio altísimo, mientras que hay algunos valores atípicos de altos ingresos que no alcanzan el máximo nivel de prestigio. El dinero influye, pero no es el único determinante.

```


# Gráfica 3: Prestigio Promedio por Tipo de Ocupación (Versión Mejorada)
plt.figure(figsize=(8, 6))
# Calculamos el prestigio promedio agrupando por 'type_num'
promedio_prestigio_tipo = df.groupby('type_num')['prestige'].mean()
# Filtramos el tipo 0
if 0 in promedio_prestigio_tipo:
    promedio_prestigio_tipo = promedio_prestigio_tipo.drop(0)
# Creamos el gráfico de barras
promedio_prestigio_tipo.plot(kind='bar', color=['#4C72B0', '#55A868', '#C44E52'])

# Reemplazamos los números por los nombres reales
nombres_grupos = ['Prof / Gerencial', 'Manual u Operativo', 'Administrativo, Oficina']
plt.xticks(ticks=[0, 1, 2], labels=nombres_grupos, rotation=0)

plt.xlabel('Categoría de Ocupación')
plt.ylabel('Prestigio Promedio')
plt.title('Prestigio Promedio por Tipo de Ocupación')

plt.show()

```



El gráfico de barras evidencia una marcada jerarquía social en las ocupaciones. El Tipo 1 concentra los niveles de prestigio promedio más altos. Por el contrario, el Tipo 2 presenta el prestigio promedio más bajo. En el contexto de la industria de software, esto subraya la importancia de la especialización técnica para alcanzar roles de mayor valoración.

ACTIVIDAD 4. ANALISIS DE AGRUPACION DE OCUPACIONES.

```
# 5. Imprimir los centroides |
print("--- Modelo con 4 Clústeres ---")
print(df.groupby('Cluster_4')[columnas_cluster].mean().round(2))
print("\n--- Modelo con 5 Clústeres ---")
print(df.groupby('Cluster_5')[columnas_cluster].mean().round(2))
```



```
✓ --- Modelo con 4 Clústeres ---
      education  income  women  prestige  type_num
Cluster_4
0           13.59  7329.35  36.35     63.33      0.95
1           8.82  5878.74   9.60     37.26      2.09
2          10.12  3545.04  74.16     37.76      2.57
3          14.69 15746.83   6.00     74.23      1.00

--- Modelo con 5 Clústeres ---
      education  income  women  prestige  type_num
Cluster_5
0           10.94  3909.12  73.76     41.50      2.88
1           9.31  6922.03   5.84     42.18      2.25
2          13.59  7329.35  36.35     63.33      0.95
3           7.78  3327.48  34.10     26.87      1.71
4          14.69 15746.83   6.00     74.23      1.00
```

Al comparar los centroides de ambos modelos, se evidencia que el paso a 5 clústeres conserva intactos los grupos fundamentales identificados en el modelo de 4, limitándose únicamente a tomar el clúster de alta gerencia y fragmentarlo en dos subcategorías basadas en la diferencia de riqueza. Dado que esta subdivisión no revela un perfil laboral nuevo que aporte valor estratégico adicional para la gestión de talento, se justifica que el modelo de 4 agrupaciones resulta ser la opción más robusta, coherente y útil para interpretar las ocupaciones y tomar decisiones organizacionales.

En el modelo de cuatro agrupaciones, el grupo que tiende a tener el mayor prestigio es el Clúster 1 ("Alta Gerencia y Técnicos Senior"), destacándose con un valor en su centroide de 0.99. Este alto nivel de valoración social está directamente impulsado por las características de las ocupaciones que lo conforman, las cuales exigen los mayores niveles de educación formal y, en consecuencia, perciben los ingresos más elevados de toda la muestra.

En el extremo opuesto, el grupo con el menor prestigio corresponde al Clúster 0 ("Operativos y Administrativos Base"), presentando el nivel más bajo del modelo con un centroide de - 0.95. Este resultado refleja que las ocupaciones agrupadas en este segmento se caracterizan por requerir los menores niveles educativos y ofrecer salarios que se encuentran significativamente por debajo del promedio general.

ACTIVIDAD 5. INTERPRETACION ORIENTADA A PRODUCCION INDUSTRIAL DE SOFTWARE.

1. ¿Qué variables parecen tener mayor relación con el prestigio de una ocupación?
De acuerdo con el análisis de correlación que ejecuté, la educación y el nivel de ingresos son las variables que tienen la relación positiva más fuerte con el prestigio ocupacional. En un entorno de producción industrial de software, esto significa que los roles que exigen mayor especialización técnica, certificaciones y que consecuentemente ofrecen mejores salarios, son percibidos con mayor valor estratégico. Para la toma de decisiones, la empresa debe utilizar esta información para estructurar bandas salariales coherentes, asegurando que la compensación refleje adecuadamente los años de estudio y preparación técnica requeridos, lo cual es vital para atraer y retener al mejor talento del mercado.
2. ¿Cómo podría una empresa de software usar este tipo de análisis para valorar roles técnicos, gerenciales o de soporte?
Este tipo de análisis nos permite salir de la subjetividad y estructurar la gestión del talento basándonos estrictamente en datos. Por ejemplo, al agrupar los perfiles según su nivel educativo e ingresos, la empresa puede diseñar paquetes de beneficios y cálculos de compensación justos que premien el esfuerzo de quienes están en áreas de soporte especializado o infraestructura técnica. Así, podemos justificar promociones internas o ajustes de sueldo hacia roles de arquitectura de datos o gerencia, respaldando la decisión en el valor real que cada posición aporta a la cadena de producción de la organización.
3. ¿Qué grupos de ocupaciones se identificaron y cómo podrían interpretarse?
Al aplicar el modelo de cuatro agrupaciones, identifiqué perfiles muy definidos que abarcan desde roles operativos base hasta alta gerencia y técnicos senior. A nivel interpretativo y estratégico, el grupo más revelador es el de "profesionales de soporte calificado": un segmento que, a pesar de tener una educación formal alta, presenta ingresos por debajo del promedio. En nuestra industria, esto podría representar a los analistas de calidad, especialistas en redes o personal de soporte técnico. Detectar este grupo nos permite mapear exactamente dónde la organización corre el riesgo de sufrir fugas de talento por mantener salarios poco competitivos frente a la alta exigencia académica del puesto.
4. ¿Existen resultados que parezcan anómalos o difíciles de explicar?
Un hallazgo que resulta anómalo y que requiere atención gerencial es precisamente la brecha encontrada en el clúster de profesionales con altos niveles de educación formal, pero con ingresos inferiores a la media, el cual coincide además con una alta participación femenina. Aunque matemáticamente el algoritmo agrupa estos datos a la perfección, a nivel corporativo expone una clara descompensación salarial o una subvaloración histórica de ciertos roles. Para solucionar esto, propondría implementar auditorías de equidad interna para garantizar que el talento técnico y administrativo reciba una remuneración basada en sus capacidades y aportes, eliminando cualquier sesgo heredado en las estructuras de pago.

5. ¿Qué información adicional haría falta para tomar mejores decisiones?

Para tomar decisiones gerenciales definitivas en una fábrica de software necesitaríamos integrar variables métricas propias del sector tecnológico. Nos haría falta conocer datos precisos como los índices de rotación de personal, los años de experiencia específicos en lenguajes de programación, métricas de productividad por área y el costo de adquisición de nuevo talento. Cruzar nuestra agrupación actual de K-Means con este tipo de indicadores internos nos permitiría diseñar un plan de desarrollo organizacional verdaderamente escalable y a la medida de nuestras operaciones.

CONCLUSIONES Y RECOMENDACIONES

La educación y el sueldo definen el valor profesional: Se demostró mediante el análisis de correlación que los años de preparación académica y el nivel de ingresos son los dos factores estadísticos principales que impulsan el prestigio de un rol.

Existen cuatro perfiles organizacionales definidos: El algoritmo de segmentación confirmó que la fuerza laboral se agrupa naturalmente en cuatro grandes niveles: alta gerencia/técnicos senior, profesionales de soporte calificado, técnicos de mantenimiento y personal operativo base.

Brechas de talento subvalorado: Se identificó un clúster específico (conformado con alta participación femenina) que, a pesar de poseer niveles de educación formal superiores a la media, percibe ingresos por debajo del promedio general, lo que indica una descompensación salarial.

Recomendaciones

Ajuste de Bandas Salariales: Se recomienda realizar una auditoría de compensaciones enfocada en los roles de soporte técnico y aseguramiento de calidad (QA). Es vital ajustar los salarios de estos perfiles para que correspondan a su alto nivel de exigencia educativa, mitigando así el riesgo de fuga de cerebros.

Planes de Carrera Basados en Formación: Dado que la educación formal es el mayor predictor de prestigio y crecimiento, la empresa debe implementar programas de certificación continua. Esto permitirá al personal de niveles operativos transitar hacia posiciones técnicas de mayor valor.

Reclutamiento Basado en Datos: Utilizar la perfilación de estos cuatro grupos descubiertos para estandarizar las futuras contrataciones, asegurando que las ofertas económicas estén estrictamente alineadas con las capacidades técnicas y el valor que el rol aportará a la línea de producción de software.

Link de repositorio de GitHub

<https://github.com/BryanJimenezUtec/Caso-Practico/tree/main>